COM450 · Calidad de Software · USFX

# Práctica 9 — IA aplicada a la Calidad de Software

Pruebas y manuales generados con IA, medidos con cobertura y mutación, y verificados contra la aplicación

David Luján · trabajo individual · 16 de octubre de 2026

# Contexto: escribir dejó de ser lo caro; verificar, no

### Qué hace bien la IA

- Propone casos y estructura en segundos
- Redacta manuales, ayudas y FAQ
- Sugiere zonas sin probar

### Riesgos que vimos en esta práctica

- **Sesgo de confirmación:** la ronda 1 fijó un defecto del código
- **Alucinación:** funciones y mensajes inventados (reto)
- **Falsa seguridad:** 100 % de cobertura con 60,71 % de mutación
- **Fuga de datos:** modelos gratuitos que entrenan con los prompts

# Comparativa — herramientas de pruebas

Mismo prompt mínimo sobre `descuentos.ts`, conversación nueva, medido con el mismo script (Vitest + tsc + Stryker).

| Herramienta | Pruebas | Verdes | tsc | Mutación | Observación |
|---|---|---|---|---|---|
| Claude (Opus 5.5) | 26 | 26 | **limpio** | 100 % | Explica cada caso |
| OpenCode + Big Pickle | 37 | 37 | **limpio** | 100 % | Instaló vitest y ejecutó comandos solo |
| OpenCode + MiMo | 26 | 26 | **6 errores** | 100 % | Usa `process`: rompe el build |
| OpenCode + DeepSeek | 18 | **17** | **limpio** | no medible | Inventa un redondeo (1,005 → 1,01) |

Nemotron y Step: error 400 del proveedor. Copilot: investigado, no probado.

# Matriz ponderada — pruebas

| Criterio | Peso | Claude | Big Pickle | MiMo | DeepSeek |
|---|---|---|---|---|---|
| Compatibilidad TS / Vitest | 25 | 5 | 5 | 3 | 4 |
| Control del contexto | 20 | 5 | 3 | 4 | 4 |
| Costo y plan gratuito | 15 | 3 | 5 | 5 | 5 |
| Privacidad | 15 | 3 | 1 | 2 | 2 |
| Calidad en la muestra | 25 | 5 | 5 | 3 | 2 |
| **Total** | **100** | **88** | **80** | **67** | **67** |

# Herramienta elegida A: Claude

**Cómo funciona:** LLM conversacional/agente; recibe código, reglas, archivos e imágenes; cada ronda en una conversación nueva.

**Ventajas:** acepta reglas de negocio, compila a la primera, explica y señala huecos de la especificación.

**Limitaciones:** si lee el código, reproduce sus defectos; plan de pago para Claude Code; hay que desactivar el entrenamiento.

**Por qué:** empata en calidad con Big Pickle, pero gana en privacidad y control (no actúa solo). Declarado: también la comodidad.

# Resultados: tres rondas sobre `cupones.ts`

| Ronda | Entrada | Pruebas | Cobertura | Mutación | ¿Correctas? |
|---|---|---|---|---|---|
| 1 | Solo código | 48 | 100 % | 100 % | **Fijan el defecto UTC** |
| 2 | + reglas | 38 | 100 % | 100 % (UTC) | Encuentran el defecto, pero dependen de la zona horaria |
| 3 | + evidencia | 39 | 100 % | 100 % UTC · 98,31 % La Paz | **Deterministas, detectan el defecto** |

El cupón vencía a las **20:00** del día de vencimiento en Bolivia (`toISOString` = UTC). **100 % de mutación no garantiza que el valor esperado sea correcto.**

# Comparativa — herramientas de manuales

| Herramienta | Entrada | Salida | Plan gratuito | Probada |
|---|---|---|---|---|
| Claude | Inventario + capturas | Markdown → HTML/PDF | Sí, con límite | Sí |
| OpenCode DeepSeek / MiMo | Inventario + capturas | Markdown | Gratis (entrena con datos) | Sí |
| Scribe | Grabación de pasos | Guía web | Sin exportación PDF/HTML | No |
| Tango | Grabación de pasos | Guía web | ~5 flujos | No |
| Guidde | Grabación + voz | Video | Marca de agua, sin descarga | No |

# Matriz ponderada — manuales

| Criterio | Peso | Claude | DeepSeek | MiMo | Scribe | Tango | Guidde |
|---|---|---|---|---|---|---|---|
| Formato de salida | 20 | 5 | 5 | 5 | 2 | 2 | 1 |
| Control del contexto | 20 | 5 | 4 | 4 | 2 | 2 | 2 |
| Costo / exportación | 20 | 4 | 5 | 5 | 1 | 2 | 1 |
| Privacidad | 15 | 3 | 2 | 2 | 2 | 2 | 2 |
| Calidad en la muestra | 25 | 4 | 3 | 4 | n/p | n/p | n/p |
| **Total** | **100** | **84** | **76** | **80** | **35/75** | **38/75** | **27/75** |

# Herramienta elegida B: Claude con inventario

- **Tipo de manual:** manual de usuario en Markdown → HTML/PDF con capturas reales, FAQ y referencia rápida
- **Ventajas:** usa los nombres exactos del inventario, marca "NO VERIFICADO" en vez de inventar, 0 alucinaciones
- **Limitaciones:** es tan veraz como su fuente: repitió el error de mi inventario (decimales con coma)
- **Las herramientas de captura** (Scribe, Tango, Guidde) no exportan en el plan gratuito: descartadas para un PDF

# El manual y la verificación

# 74,4 %

32 de 43 afirmaciones correctas en la versión IA 1. 0 alucinaciones, 4 datos incorrectos, 4 de formato, 3 omisiones.

**Error más grave:** "admite decimales, por ejemplo 33,33" → el campo descarta la coma: **Bs 2999,70** en vez de **Bs 30,00**, sin aviso.



# El reto: la IA que miente

### Pruebas (B1–B6), un commit cada una

- Mensaje en inglés · función inexistente
- `toBeDefined()` que pasa con `null`
- Prueba sin `expect` · `it.skip` en el límite
- Tautología: repite la fórmula

100 % de líneas con **60,71 %** → **82,14 %** de mutación

### Manual (M1–M8)

- Alucinaciones: inicio de sesión, Historial
- Datos: rango 0–90, botón "Aplicar descuento", redondeo hacia abajo, mensaje único, pie
- Formato: `$150.00` en vez de `Bs 150,00`

# Conclusiones y recomendación

- La IA ahorra la escritura; más del 85 % del tiempo fue **verificar**
- Cobertura y mutación no dicen si el valor esperado es correcto: lo dice la regla de negocio
- Un control mal configurado engaña: 46 *timeouts* inflaron el puntaje del CI hasta bajar la concurrencia
- La verdad terreno también se verifica: mi inventario tenía el error de la coma
- **Política:** nada de secretos en prompts, lista de control + pipeline obligatorios, bitácora, umbral de mutación tipo trinquete (98)
- **Recomendación:** usen la IA para generar, nunca para juzgar; midan con mutación y verifiquen cada afirmación de alto riesgo